


# L'intelligence artificielle & l'algorithme kNN



Depuis plusieurs années les grandes firmes de l'internet (GAFA) investissent énormément d'argent dans les recherches portant sur l'intelligence artificielle. Des chercheurs français comme Yann Le Cun (très connu pour ces publications sur les neurones profonds) se sont particulièrement illustrés par leurs recherches et sont devenus très sollicités par les médias pour vulgariser leurs travaux auprès du grand public. Mais comment expliquer simplement la modélisation mathématique d'un concept aussi abstrait que l'intelligence ?

Ce terme d'intelligence artificiel est devenu finalement un four-tout très souvent utilisé à défaut. En fait il s'agit de la faculté de reproduire un "raisonnement" par des moyens informatiques. C'est l'ordinateur qui "pense" pour reconnaître, s'adapter à des situations comme le ferait un être humain.



*C'est logique ! Où il y a de l'intelligence artificielle, il a forcément de la stupidité artificielle.*

## 1. Technique de création d'intelligence artificielle

L'algorithme k-Nearest Neighbors (kNN) se situe principalement dans le domaine de l'apprentissage automatique (Machine Learning), plus précisément dans la catégorie des algorithmes d'apprentissage supervisé.

| Catégorie                 | Sous-catégorie          | Description                                                                                   |
|---------------------------|-------------------------|-----------------------------------------------------------------------------------------------|
| Apprentissage automatique | Apprentissage supervisé | KNN est utilisé pour la <b>classification</b> et la <b>régression</b> .                       |
| Type d'algorithme         | Basé sur l'instance     | Il ne construit pas de modèle, mais compare les nouvelles données aux données d'entraînement. |
| Type d'IA                 | IA à mémoire limitée    | KNN utilise les données passées (le jeu d'entraînement) pour prendre des décisions.           |

Le sous ensemble le plus en vue de nos jours attire au champ d'étude du machine learning au sein duquel quatre catégories d'apprentissage sont mises en lumière :



### Apprentissage non-supervisé

Pour traiter des données non classées:

- Partitionnement des données,
- Trouver des similitudes dans un échantillon de données,
- Réduire la dimension de l'échantillon...



### Apprentissage par transfert

Appliquer les algorithmes construits sur une tâche antérieure et les appliquer à une nouvelle tâche:

- Trouver des similitudes entre les tâches pour effectuer le transfert de connaissance,
- Augmenter le champs d'action d'une IA



### Machine Learning

### Apprentissage supervisé



Convient à des tâches précises:

- Classification,
- Prédiction,
- Étiquetage de données...



### Apprentissage par renforcement

Pour réagir à des événements connus:

- Recommandations,
- Aide à la décision,
- Notation...



### L'algorithme des K plus proches voisins

L'algorithme des K plus proches voisins s'écrit en abrégé k-NN ou kNN, de l'anglais k-Nearest Neighbors où k est un nombre positif généralement petit.


Il s'agit d'un algorithme de machine learning (apprentissage machine) qui est essentiel dans le milieu de l'intelligence artificielle.

Le principe peut être résumé par 'Dis-moi qui sont tes amis et je te dirai qui tu es'.

#### **Idée générale**

1. On considère une population dont on connaît la classe et les caractéristiques.
2. On introduit un nouvel élément dont on ne connaît que les caractéristiques et on cherche à lui attribuer une classe.
3. Ayant choisi une distance adaptée, on compte les k **voisins les plus proches** de l'élément à classer. On lui attribue alors la classe des voisins majoritaires.

Pour effectuer une prédiction de classification, l'algorithme kNN va se baser sur le jeu de données en entier. En effet, pour une observation, qui ne fait pas parti du jeu de données, qu'on souhaite prédire, l'algorithme va chercher les K instances du jeu de données les plus proches de notre observation. Ensuite pour ces k voisins, l'algorithme se basera sur leurs variables de sortie (output variable), pour calculer la valeur de la variable de l'observation qu'on souhaite prédire. **Remarque** : si k est impair, il ne peut pas y avoir d'ex aequo.



Ce genre d'algorithme permet par exemple de prédire le comportement d'une personne en s'intéressant à son milieu. Il était utilisé par les géants de la vente comme Amazon, Netflix ... afin de prévoir si vous seriez ou non intéressé par un produit. En effet, en disposant de vos données (âge, derniers achats, ...) et en les comparant à celles de clients similaires, un algorithme peut tâcher de prédire si vous seriez intéressés ou non par le produit.

**Q1.** A partir de la description précédente, **indiquer** la méthode d'analyse utilisée par l'algorithme kNN (méthode experte ou méthode neuronique). **Justifier** la réponse.

**Cet algorithme permet de résoudre un problème de classification** : on dispose d'un ensemble E d'éléments et d'un ensemble C de classes

Chaque élément  $e_i$  de E est associé à une et une seule classe  $c_j$  de C.

L'objectif de l'algorithme de classification est de **prédire la classe c d'un élément e**.

Pour cela on dispose d'une base de données d'apprentissage constituée de N couples d'associations correctes ( $e_i, c_j$ ) . Pour estimer la classe associée à un nouvel élément e, la méthode des k plus proches voisins consiste à prendre en compte (de façon identique) les k échantillons d'apprentissage les plus proches de e, selon une distance à définir en fonction du problème.

**Remarque** : Lorsque le problème consiste à estimer une valeur numérique (sur une moyenne des voisins ou autre) et non une classe, on parle de **problème de régression**.




## 2. Classification de joueurs de rugby

Le rugby est un sport collectif où se côtoient 30 joueurs de morphologies très variées. Cependant quelques soient les équipes, les joueurs évoluant à un poste donné sont tous de même morphotype. Par exemple les ailiers sont très souvent pas très grand et légers alors que les deuxième ligne sont très grands et assez lourds. Il y a donc un lien direct entre la stature du joueur et le poste sur lequel il évolue.

Objectif de l'activité : Déterminer le meilleur poste à attribuer à un nouveau joueur de rugby en fonction de ses caractéristiques morphologiques (poids, taille).

### Principe de classification

Le site <http://www.allrugby.com> référence la taille et le poids des différents joueurs du Top14 ainsi que leur poste sur le terrain au cours de la saison 2019-2020. A partir de ce jeu de données, il est possible de représenter sous forme graphique les postes des joueurs de Toulouse selon leur morphologie :



### Principe de prédiction de l'algorithme kNN

Pour classer un nouvel individu, ici attribuer le meilleur poste selon son gabarit, il suffit de rechercher dans le jeu de données le joueur dont la morphologie est la plus proche et d'attribuer au nouveau joueur le même poste que ce joueur.


**Q2.** A partir de cette méthode de prédiction, **déterminer** le meilleur poste à attribuer aux nouveaux joueurs suivants :

|          | Taille (m) | Masse (kg) | Poste |
|----------|------------|------------|-------|
| Joueur 1 | 1,95       | 112        |       |
| Joueur 2 | 1,75       | 91         |       |
| Joueur 3 | 1,82       | 90         |       |
| Joueur 4 | 1,85       | 108        |       |



## Influence du facteur k

La figure ci-dessous détaille la zone d'étude du joueur 4



**Q3. Critiquer** le résultat obtenu pour le joueur 4.

La classification peut être améliorée en tenant compte des k plus proches voisins et en attribuant au nouveau joueur la classe majoritaire de ses voisins.

**Q4. Classifier** le joueur 4 pour k = 5. **Décrire** le rôle de k dans l'algorithme des k plus proches voisins.

**Remarque concernant le choix de la valeur de k :** Le choix de la valeur de k peut affecter les performances de l'algorithme. Si k est trop petit, l'algorithme peut être sensible aux points aberrants (valeurs extrêmes), ce qui peut entraîner une mauvaise classification. Si k est trop grand, cela peut entraîner une baisse de la précision de l'algorithme, car les données voisines peuvent ne pas être représentatives de la nouvelle donnée d'entrée. Diverses considérations théoriques et expérimentales mènent à choisir  $k \approx \sqrt{e/C}$ , avec e est le nombre d'éléments et C le nombre de classes.

**Q5. Calculer** la valeur de k à choisir à priori pour cet exemple.

## 3. Programmation de l'algorithme kNN

Pour prédire la classe d'un nouvel élément il faut donc :

- ➔ Calculer la distance qui sépare le nouvel élément de chacun des autres points du jeu de données.
- ➔ Stocker ces valeurs de distance  $d$  dans une liste du type  $[[d, i], [...], ...]$ . Avec  $d$  la distance qui sépare le nouvel élément du point d'indice  $i$ .
- ➔ Déterminer l'indice du voisin le plus proche
- ➔ Assigner la classe au nouvel élément.

## Fonctions mises en œuvre

On mettra en œuvre 4 fonctions :

- Une fonction `extractionDonnees(fichier)` qui charge en mémoire le jeu de données stocké dans un fichier CSV. Cette fonction est déjà réalisée, elle renvoie une liste de t-uplet contenant :

(Nom du joueur, Type de poste, Taille, Masse)

- Une fonction `distance(p1, p2)` qui calcule et renvoie la distance euclidienne séparant deux points `p1` et `p2`
- Une fonction `distance_voisins(p1, jeu2donnees)` qui renvoie la liste des distances séparant le point `p1` (nouveau joueur) de chaque point du jeu de données.
- Une fonction `predire_classe(distances, jeu2donnees)` qui renvoie la classe à attribuer au nouveau joueur

Le code incomplet de cette application nommé `knn.py` est à télécharger depuis Eléa.

### Implémentation de la fonction *distance*

**Q6. Compléter** en suivant la spécification, la fonction `distance`. **Valider** la fonction avec le test proposé dans la spécification.

Pour rappel, dans un repère orthonormé du plan, la distance euclidienne séparant deux points  $A(x_A; y_A)$  et  $B(x_B; y_B)$  se calcule par la formule  $\sqrt{(x_B - x_A)^2 + (y_B - y_A)^2}$

### Implémentation de la fonction *distance\_voisins*

**Q7. Compléter** en suivant la spécification, la fonction `distance_voisins`. **Valider** la fonction avec le test proposé dans la spécification.

### Implémentation de la fonction *predire\_classe*

**Q8. Compléter** en suivant la spécification, la fonction `predire_classe`. **Valider** la fonction avec le test proposé dans la spécification.

## 4. Test de l'algorithme kNN

On souhaite vérifier le fonctionnement du code développé en l'appliquant sur les joueurs définis à la question Q2 et avec le jeu de données constitué des joueurs de Toulouse (`joueursToulouse.csv`). Ce test consiste à vérifier la classe de chaque nouveau joueur déterminée par le programme ainsi que le nom du plus proche voisin.

**Q9. Faire évoluer** le programme pour obtenir les informations demandées. **Vérifier** la validité du programme avec les résultats obtenus en question Q2

## 5. Pour aller plus loin

Le travail réalisé sur cette première partie permet d'appliquer l'algorithme kNN pour une valeur de  $k = 1$ .

**Q10. Modifier** la fonction `predire_classe` afin de pouvoir choisir la valeur de  $k$ . Il est demandé de définir si besoin de nouvelles fonctions pour améliorer la lisibilité du code.

